cedia | TMO
Training Management Office

info@cedia.org.ec
cedia.edu.ec

METODOLOGÍA HEFESTO PARA MODELADO DIMENSIONAL

Cómo identificar hechos, dimensiones, grano, indicadores y construir un esquema estrella paso a paso

Objetivos de Aprendizaje

- Entender qué es un Data Warehouse y un Data Mart
- Diferenciar sistemas OLTP y OLAP
- Aplicar la metodología HEFESTO paso a paso
- Identificar preguntas de negocio, indicadores y perspectivas
- Definir el grano de la tabla de hechos
- Construir tablas de hechos y dimensiones
- Transformar un modelo OLTP en un modelo dimensional

Recordatorio: OLTP

Online Transaction Processing

Sistema diseñado para registrar operaciones del día a día.

- Muchas operaciones pequeñas (INSERT, UPDATE)
- Datos muy detallados y normalizados
- Optimizado para transacciones rápidas
- Ejemplos: Ventas, matrículas, pagos

Prioridad del OLTP

- Registrar bien y rápido
- Evitar inconsistencias
- Mantener integridad referencial

NO está pensado para:
Preguntas analíticas complejas como "ingresos por carrera por mes" o "cursos más demandados".

Recordatorio: JOIN en SQL

Un **JOIN** es una operación que permite unir filas de dos o más tablas a través de un campo relacionado (clave primaria y foránea).

ESTUDIANTE (e)

id_estudiante	nombre
E001	Juan Pérez
E002	Ana Gómez

+

INSCRIPCION (i)

id_insc	id_estudiante	monto
1001	E001	300
1002	E002	450

→

RESULTADO

id_insc	nombre	monto
1001	Juan Pérez	300
1002	Ana Gómez	450

```sql
SELECT i.id_inscripcion, e.nombre, i.monto FROM INSCRIPCION i
JOIN ESTUDIANTE e ON i.id_estudiante = e.id_estudiante;
```

Idea Pedagógica Clave

Un JOIN no "inventa" datos, solo reúne datos que ya están repartidos entre varias tablas.

En OLTP: Se necesitan muchos JOINs para análisis.
En OLAP: El modelo dimensional reduce esta complejidad.

Recordatorio: OLAP y Data Warehouse

OLAP (Online Analytical Processing)

Pensado para analizar información histórica, no para registrar transacciones en tiempo real.

- Responde: "¿Cuánto vendimos por mes?"
- Pocas escrituras, muchas lecturas
- Consultas pesadas y agregaciones

Data Warehouse

Repositorio central de datos integrado y orientado al análisis. Consolida múltiples fuentes.

- Análisis histórico y tendencias
- Fuente para Dashboards y BI
- Datos organizados por temas

Analogía: *Si el OLTP es la "caja registradora" del supermercado, el Data Warehouse es el "centro de análisis" que resume todo lo ocurrido en todas las cajas, todos los días.*

Data Mart: Subconjunto del Data Warehouse

Una vista específica orientada a un área del negocio

Concepto	Data Warehouse	Data Mart
Alcance	Toda la organización	Un área específica
Tamaño	Mayor (Terabytes/Petabytes)	Menor (Gigabytes)
Usuarios	Toda la empresa	Un departamento
Ejemplo	Datos globales universitarios	Solo matrículas

Analogía

Data Warehouse = Biblioteca completa

Data Mart = Una sección especializada (ej. Ciencias)

Ejemplos Universitarios

- Data Mart Académico
- Data Mart Financiero
- Data Mart Admisiones

El problema de usar OLTP para analítica

Responder preguntas analíticas requiere JOINs complejos

PREGUNTA DE NEGOCIO

"¿Cuánto ingreso generó cada curso por mes y por carrera?"

REALIDAD EN OLTP (11 TABLAS)

- INSCRIPCION
- DETALLE_INSCRIPCION
- OFERTA_CURSO
- CURSO
- DOCENTE
- PERIODO_ACADEMICO
- ESTUDIANTE
- PERSONA
- PROGRAMA_ACADEMICO
- FACULTAD
- CIUDAD

Consultas Complejas

Tiempos de Respuesta Lentos

Difícil Mantenimiento

Modelado Dimensional: Conceptos Clave

HECHOS

¿Qué queremos medir?

Son las medidas numéricas del evento de negocio. Contienen datos cuantitativos como ingresos, cantidad de inscripciones, duración, etc.

DIMENSIONES

¿Desde qué perspectivas analizamos?

Son tablas descriptivas que dan contexto al hecho. Permiten filtrar y agrupar (por estudiante, por curso, por tiempo, por ubicación).

GRANO

¿Qué representa una fila?

Es la definición exacta del nivel de detalle de la tabla de hechos. Debe poder expresarse en una frase simple (ej: "una inscripción diaria").

AGREGACIÓN

¿Cómo resumimos los datos?

Es el proceso de resumir datos detallados en información útil mediante operaciones matemáticas: SUM, COUNT, AVG, MIN, MAX.

¿Qué es la Metodología HEFESTO?

> *HEFESTO empieza preguntando "¿Qué necesita analizar el negocio?", no "¿Qué tablas tengo?"*

Es una metodología propia para la construcción de Data Warehouses que pone el foco primero en las **preguntas del negocio**, luego en los indicadores y perspectivas, y finalmente en el modelo lógico.

- Evita modelar a ciegas
- No copia el modelo OLTP tal cual
- Identifica correctamente hechos y dimensiones
- Diseña un Data Mart útil para el negocio

EL FLUJO MENTAL CORRECTO

Preguntas Negocio → Indicadores → Perspectivas → Revisión OLTP → Hechos → Dimensiones → **Modelo Estrella**

Las 4 Fases de HEFESTO

Estructura metodológica desde los requerimientos hasta la integración

FASE	NOMBRE	DESCRIPCIÓN
1	**Análisis de Requerimientos**	Se identifican preguntas del negocio, indicadores y perspectivas de análisis.
2	**Análisis de los OLTP**	Se estudian las tablas fuente para validar que los datos necesarios existan.
3	**Modelo Lógico del DW**	Se diseña la estructura dimensional: hechos, dimensiones, relaciones y grano.
4	**Integración de Datos**	Se define cómo cargar la información desde OLTP al modelo analítico (ETL).

FASE 1: Análisis de Requerimientos

El enfoque "Top-Down": Empezar por la necesidad del negocio

1. Preguntas de Negocio

Identificar qué información necesitan los tomadores de decisiones. Deben ser preguntas en lenguaje natural, no técnico.

"¿Cuánto vendimos por región el mes pasado?"

2. Indicadores

Extraer los valores numéricos (métricas) que responden a la pregunta. Son los datos que se van a sumar, contar o promediar.

Indicador: "Monto de Ventas"

3. Perspectivas

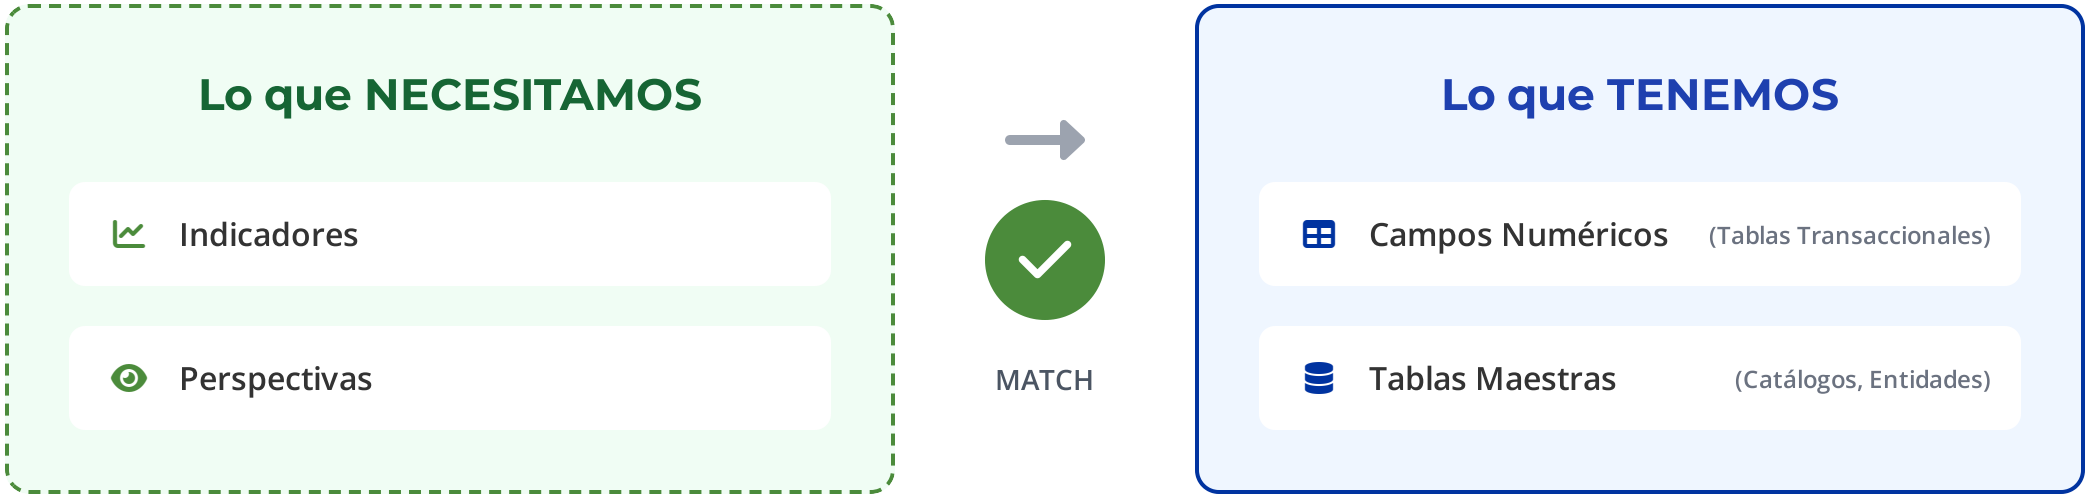
Determinar los criterios por los cuales se analizarán los indicadores. Responden al "por qué", "cuándo", "dónde" o "quién".

Perspectivas: "Tiempo", "Región"

Clave HEFESTO: No mires la base de datos todavía. Primero define qué quieres saber.

FASE 2: Análisis de los Data Sources

Validación: ¿Tenemos los datos para responder?



⚠ **Regla de Oro:** Si un indicador o perspectiva no existe en el OLTP, se debe descartar la pregunta o buscar fuentes externas.

FASE 3: Modelo Lógico del Data Warehouse

Construyendo el Esquema Estrella

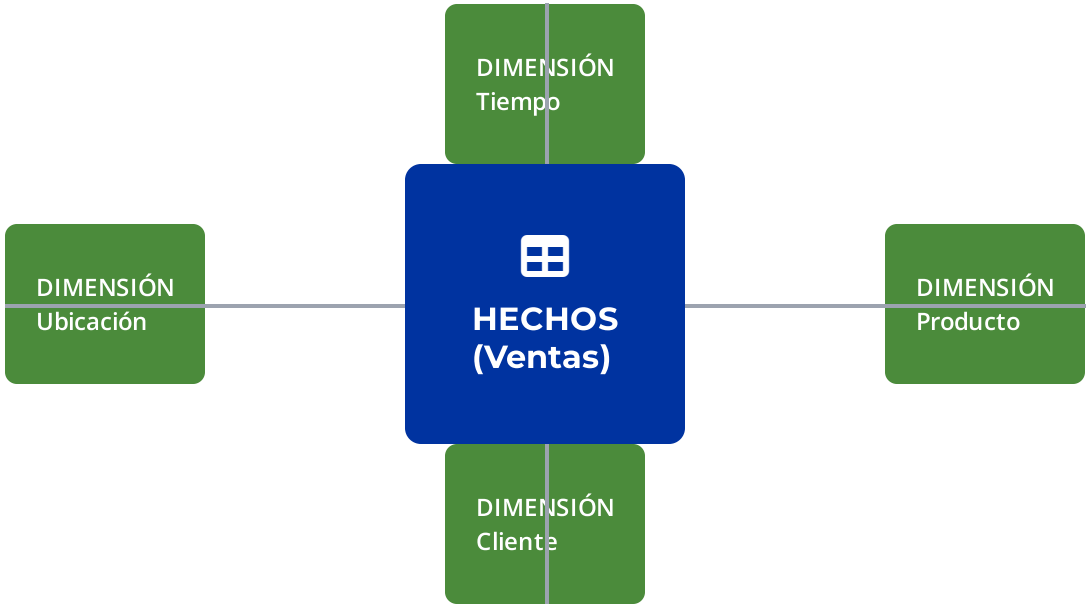


Tabla de Hechos (Fact Table)

Contiene los números (métricas) del negocio. Es la tabla central y más grande. Registra los eventos (ej. cada venta, cada clic).

Tablas de Dimensiones

Contienen el contexto (texto descriptivo). Responden a Quién, Qué, Cuándo, Dónde. Son pequeñas y desnormalizadas.

El Grano (Granularidad)

El nivel de detalle de una fila en la tabla de hechos.
Ejemplo: "Una fila por cada producto vendido en cada ticket".

FASE 4: Integración de Datos (ETL)

Poblando el Data Warehouse: Extracción, Transformación y Carga



1. EXTRACCIÓN

- Leer bases de datos OLTP (SQL, Oracle).
- Leer archivos planos (CSV, Excel).
- Conectar a APIs externas.
- **Objetivo:** Obtener la materia prima.



2. TRANSFORMACIÓN

- Limpieza de datos (nulos, duplicados).
- Estandarización (Mayúsculas, formatos).
- Cálculo de métricas derivadas.
- Búsqueda de claves (Surrogate Keys).



3. CARGA

- Insertar en Dimensiones primero.
- Insertar en Tabla de Hechos después.
- Manejo de historial (SCD).
- **Resultado:** Datos listos para analizar.

"El ETL consume el 70-80% del tiempo de un proyecto de BI."

Caso de Estudio: Universidad

Aplicación práctica de la metodología HEFESTO

Necesidad del Negocio:
La universidad desea analizar el comportamiento de sus **inscripciones** y los **ingresos académicos** generados para tomar mejores decisiones estratégicas.

PREGUNTAS DE NEGOCIO A RESOLVER

1. ¿Cuánto ingreso generó cada curso por mes?
2. ¿Cuántas inscripciones hubo por programa académico?
3. ¿Cuál es el docente con más inscripciones?
4. ¿Cuántos estudiantes únicos se inscribieron por mes?
5. ¿Qué ciudad aporta más ingresos?

FASE 1 - Paso 1: Identificar Preguntas del Negocio

El punto de partida de todo el proceso HEFESTO

Las preguntas del negocio definen qué necesita saber la organización. Son el insumo principal para identificar:

- Qué medir (Hechos)
- Desde qué perspectivas analizar (Dimensiones)

> Estas preguntas guían todo el diseño dimensional posterior.

1. ¿Cuánto ingreso generó cada curso por mes?
2. ¿Cuántas inscripciones hubo por programa académico?
3. ¿Cuál es el docente con más inscripciones?
4. ¿Cuántos estudiantes únicos se inscribieron por mes?
5. ¿Qué ciudad aporta más ingresos?

FASE 1 - Paso 2: Identificar Indicadores

Los indicadores son las medidas numéricas que responden a las preguntas del negocio

Técnica Práctica

Busca palabras clave en las preguntas como: `cuánto` `total` `número de` `cantidad de` `promedio`

Pregunta del Negocio	Indicador Identificado	Agregación
¿**Cuánto** ingreso generó cada curso?	Ingreso	SUM
¿**Cuántas** inscripciones hubo por programa?	Cantidad de inscripciones	COUNT
¿Cuál es el docente con **más** inscripciones?	Cantidad de inscripciones	COUNT
¿**Cuántos** estudiantes únicos se inscribieron?	Estudiantes únicos	COUNT DISTINCT
¿Qué ciudad aporta **más** ingresos?	Ingreso	SUM

FASE 1 - Paso 3: Identificar Perspectivas

Las perspectivas responden al "¿Por qué criterio?" y se convierten en Dimensiones

"...generó cada curso **por mes** ?	→	TIEMPO
"...inscripciones **por programa** ?	→	PROGRAMA
"...ingreso generó **cada curso** ?	→	CURSO
"...cuál es el **docente** con más...?	→	DOCENTE
"...qué **ciudad** aporta más...?	→	GEOGRAFÍA

FASE 2 - Análisis del OLTP

Identificación de las fuentes de datos disponibles en el sistema transaccional

Objetivo: Verificar que la información requerida por los indicadores existe en las tablas del sistema fuente.

TRANSACCIONAL (HECHOS)

INSCRIPCION
id_inscripcion, fecha, estado...

DETALLE_INSCRIPCION
id_detalle, id_inscripcion, valor...

PERSONAS

ESTUDIANTE
id_estudiante, id_persona, código...

DOCENTE
id_docente, id_persona, especialidad...

PERSONA
id_persona, nombre, apellido, dni...

ACADÉMICO

CURSO
id_curso, nombre, créditos...

OFERTA_CURSO
id_oferta, id_curso, id_periodo...

PROGRAMA_ACADEMICO
id_programa, nombre, nivel...

UBICACIÓN / TIEMPO

CIUDAD
id_ciudad, nombre, provincia...

PERIODO_ACADEMICO
id_periodo, nombre, fecha_inicio...

FACULTAD
id_facultad, nombre, decano...

FASE 2 - Validación de Datos en el OLTP

Verificación de disponibilidad de datos para indicadores y perspectivas

DATO REQUERIDO	TABLA ORIGEN	COLUMNA	ESTADO
Nombre del Curso	**CURSO**	nombre	Disponible
Fecha Inscripción	**INSCRIPCION**	fecha	Disponible
Monto / Ingreso	**DETALLE_INSCRIPCION**	monto	Disponible
Nombre Programa	**PROGRAMA_ACADEMICO**	nombre	Disponible
Nombre Docente	**PERSONA**	nombres	Disponible
Ciudad	**CIUDAD**	nombre	Disponible

Conclusión: Todos los datos necesarios para responder las preguntas del negocio existen y son accesibles en el sistema transaccional.

FASE 3 - Identificación del Hecho

Seleccionando el evento central del negocio

El **Hecho** representa el proceso de negocio o evento que queremos analizar. Es la tabla central que contendrá los datos numéricos (métricas).

Hecho Seleccionado: INSCRIPCIÓN

- **Es el evento transaccional:**
  Ocurre cada vez que un estudiante toma una materia.
- **Contiene las métricas:**
  Aquí reside el valor monetario (Costo/Ingreso) y el conteo.
- **Conecta las dimensiones:**
  Vincula al Estudiante, Curso, Docente y Tiempo.



FASE 3 - Definición del Grano

El nivel de detalle más atómico de la tabla de hechos

> **Definición:** El grano responde a la pregunta *"¿Qué representa exactamente una fila en la tabla de hechos?"*. Define el nivel máximo de detalle de la información almacenada.

◎ Grano: "Una inscripción de un estudiante en un curso, dictado por un docente en un periodo específico."

Representación Visual de una Fila (Registro Único):

TIEMPO	ESTUDIANTE	CURSO	DOCENTE	PROGRAMA	UBICACIÓN	CANT.	INGRESO
202301	EST-001	CUR-101	DOC-55	PROG-A	UIO	1	$150.00

FASE 3 - Identificación de Medidas

Definición de los valores numéricos que responderán a los indicadores

INGRESOS



Representa el valor monetario generado por cada inscripción académica.

Origen:	`detalle.valor`
Agregación:	`SUM`

CANTIDAD



Conteo simple de las inscripciones realizadas para medir volumen.

Origen:	`inscripcion.id`
Agregación:	`COUNT`

ESTUDIANTES



Conteo de personas únicas matriculadas, sin duplicados.

Origen:	`estudiante.id`
Agregación:	`COUNT DISTINCT`

FASE 3 - Construcción de Dimensiones

Definición de atributos para las 5 perspectivas identificadas

DIM_TIEMPO

id_tiempo (PK)

- fecha (Date)
- anio (Integer)
- mes_nombre (String)
- dia_semana (String)
- trimestre (Integer)

DIM_ESTUDIANTE

id_estudiante (PK)

- nombre_completo (String)
- genero (String)
- fecha_nacimiento (Date)
- ciudad_residencia (String)
- provincia (String)

DIM_DOCENTE

id_docente (PK)

- nombre_completo (String)
- nivel_estudios (String)
- especialidad (String)
- tipo_contrato (String)

DIM_CURSO

id_curso (PK)

- nombre_curso (String)
- creditos (Integer)
- area_conocimiento (String)
- modalidad (String)

DIM_PROGRAMA

id_programa (PK)

- nombre_programa (String)
- facultad (String)
- nivel_formacion (String)
- director_programa (String)

FASE 3 - Tabla de Hechos FACT_INSCRIPCION

Estructura final que consolida dimensiones y métricas

FACT_INSCRIPCION		
FK	id_tiempo	INT
FK	id_estudiante	INT
FK	id_curso	INT
FK	id_docente	INT
FK	id_programa	INT
FK	id_ubicacion	INT
#	cantidad_inscripciones	INT
$	monto_ingreso	DECIMAL

Claves Foráneas (FK)

Conectan el hecho con las **Dimensiones**. Permiten "cortar" y filtrar los datos (ej. ver ingresos *por docente* o *por mes*).

Medidas (Métricas)

Son los valores numéricos que se van a **agregar** (sumar, contar, promediar). Representan el rendimiento del negocio.

Modelo Estrella Final

Esquema lógico resultante: Fact Table rodeada de Dimensiones

DIM_TIEMPO

- PK_Tiempo
- Fecha
- Mes
- Año

DIM_PROGRAMA

- PK_Programa
- Nombre
- Nivel
- Facultad

DIM_CURSO

- PK_Curso
- Nombre
- Créditos
- Tipo

FACT_INSCRIPCION

- *FK_Tiempo*
- *FK_Programa*
- *FK_Curso*
- *FK_Estudiante*
- *FK_Docente*
- *FK_Geografia*

DIM_ESTUDIANTE

- PK_Estudiante
- Nombre
- Género
- Edad

DIM_DOCENTE

- PK_Docente
- Nombre
- Especialidad
- Categoría

DIM_GEOGRAFIA

- PK_Geografia
- Ciudad
- Provincia
- País

FASE 4 - Integración de Datos (ETL)

Mapeo de reglas de negocio para poblar el Data Warehouse

ORIGEN (OLTP)	REGLA DE TRANSFORMACIÓN	DESTINO (OLAP)
`INSCRIPCION.fecha`	Desglosar (Año, Mes, Día)	`DIM_TIEMPO.*`
`ESTUDIANTE.nombre + apellido`	CONCAT & UPPERCASE	`DIM_ESTUDIANTE.nombre_completo`
`CURSO.nombre`	TRIM (Eliminar espacios)	`DIM_CURSO.nombre_curso`
`INSCRIPCION.id_inscripcion`	COUNT (Agregación)	`FACT.cantidad_inscripciones`
`DETALLE.valor`	SUM (Agregación)	`FACT.monto_ingreso`



Consultas Analíticas: Ingreso por Curso

Pregunta 1 ¿Cuánto ingreso generó cada curso por mes?

query_ingresos.sql

```sql
SELECT t.anio, t.mes_nombre, c.nombre_curso, SUM(f.monto_ingreso) AS
Total FROM FACT_INSCRIPCION f JOIN DIM_TIEMPO t ON f.id_tiempo =
t.id_tiempo JOIN DIM_CURSO c ON f.id_curso = c.id_curso GROUP BY
t.anio, t.mes_nombre, c.nombre_curso ORDER BY Total DESC;
```

Resultado (Extracto):

Año	Mes	Curso	Total
2023	Marzo	Data Science	$12,500
2023	Marzo	Python Básico	$8,200
2023	Abril	Big Data	$7,800
2023	Abril	Data Science	$6,400
2023	Marzo	Machine Learning	$5,100

Análisis

La consulta revela que **Data Science** en Marzo fue el curso más rentable. El modelo estrella permite agrupar por atributos de tiempo y producto (curso) sin JOINs complejos entre tablas transaccionales.

Consultas Analíticas: Programa y Docente

Respondiendo a las preguntas de negocio #2 y #3

2. Inscripciones por Programa

```sql
SELECT  P.nombre_programa,
 COUNT(*) AS total
FROM FACT_INSCRIPCION F
JOIN DIM_PROGRAMA P
 ON F.id_programa = P.id_programa
GROUP BY P.nombre_programa
ORDER BY total DESC;
```

nombre_programa	total
Ingeniería de Software	1,245
Administración	980
Derecho	850
Medicina	720

3. Docente con más inscripciones

```sql
SELECT  D.nombre_docente,
 COUNT(*) AS total
FROM FACT_INSCRIPCION F
JOIN DIM_DOCENTE D
 ON F.id_docente = D.id_docente
GROUP BY D.nombre_docente
ORDER BY total DESC
LIMIT 1;
```

nombre_docente	total
Dr. Juan Pérez	342

Consultas Analíticas: Estudiantes Únicos e Ingresos

Respondiendo a las preguntas de negocio #4 y #5

4. Estudiantes Únicos por Mes

```
SELECT T.mes_nombre, COUNT(DISTINCT F.id_estudiante) AS unicos FROM
FACT_INSCRIPCION F JOIN DIM_TIEMPO T ON F.id_tiempo=T.id_tiempo
WHERE T.anio=2023 GROUP BY T.mes_nombre ORDER BY unicos DESC;
```

mes_nombre	unicos
Marzo	450
Septiembre	410
Abril	120
Octubre	95

5. Ingresos por Ciudad

```
SELECT G.ciudad, SUM(F.monto_ingreso) AS total_ingreso FROM
FACT_INSCRIPCION F JOIN DIM_GEOGRAFIA G ON
F.id_ubicacion=G.id_geografia GROUP BY G.ciudad ORDER BY
total_ingreso DESC;
```

ciudad	total_ingreso
Quito	**$45,200.00**
Guayaquil	**$38,500.00**
Cuenca	**$22,100.00**
Loja	**$15,400.00**

Resumen de la Metodología HEFESTO

Los 10 pasos clave para construir un Data Mart exitoso

1

Preguntas de Negocio

Identificar qué necesita saber la organización.

2

Indicadores

Definir qué métricas responden las preguntas.

3

Perspectivas

Determinar los criterios de análisis (dimensiones).

4

Análisis OLTP

Examinar el modelo E-R transaccional.

5

Validación

Confirmar existencia de datos requeridos.

6

Hecho

Seleccionar el evento central (tabla de hechos).

7

Grano

Definir el nivel de detalle atómico.

8

Medidas

Establecer campos numéricos y agregaciones.

9

Dimensiones

Construir tablas de contexto y atributos.

10

Modelo Estrella

Consolidar el esquema lógico final.

cedia

TMO - Training Management Office

GRACIAS

Metodología HEFESTO para Data Warehousing

diego.quisi@cedia.org.ec
felipe.mendieta@cedia.org.ec

www.cedia.edu.ec